

Data Governance: Desafío Técnico

Este desafío consta de un ejercicio práctico. Es importante destacar que más allá de valorar las piezas de código generadas, se evaluará la solución integral propuesta ante los problemas, cómo se aborda el desafío de negocio y la articulación de las diferentes partes/procesos. Manos a la obra 🚀

Contexto de Negocio

En Mercado Libre nuestro ecosistema descentralizado de producción y consumo de datos hoy contiene más de 250 equipos diferentes (y +15000 empleados) quienes son responsables de la generación de datos para sus propias operaciones y para toda la empresa.

Los equipos han producido colectivamente más de 2 millones de productos relacionados con datos (tablas, dashboards, métricas), modelos de machine learning (ML) e inteligencia artificial (IA) y herramientas específicas como [Verdi](#), la cual es usada para orquestar procesos de GenAI.

Pilares de Gobierno

- **Discoverabilidad:** A medida que se incrementa el volumen de productos y datos generados, se vuelve un desafío buscar y localizar los datos relevantes cuando se necesita. La discoverabilidad se refiere a la facilidad con la que los datos o productos pueden ser encontrados, entendidos y utilizados por aquellos que los necesitan.
- **Integridad de los Datos:** Con tanta información producida por distintos equipos, es crucial mantener la calidad y precisión de los datos. Esto incluye asegurar que los datos no se dupliquen, estén actualizados y sean exactos para su uso en análisis y toma de decisiones.
- **Eficiencia Operativa:** Mientras se mejora la discoverabilidad y la integridad, también es importante que los procesos se generen siguiendo buenas prácticas de performance y haciendo un uso costo-efectivo de los recursos.

Desafío

En este contexto, el challenge consiste en proponer soluciones para mejorar la discoverabilidad y la integridad de los datos de manera eficiente. Esto podría incluir estrategias de organización de datos, implementación de herramientas de búsqueda avanzada, o metodologías para auditar y garantizar la calidad de los datos, siempre teniendo en cuenta las restricciones de eficiencia operativa que enfrenta la empresa.

Ejercicio: Enriquecimiento de Descripciones de Productos

Desarrollar un script de Python en [Google Colab](#) para extraer datos de productos mediante la [API de MercadoLibre](#) (te recomendamos usar el [buscador de productos](#) dentro de la documentación) y usar la API de [Gemini](#) (podés generar tus credenciales [acá](#)) para generar descripciones enriquecidas para estos productos. Estas descripciones mejoradas alimentarán un sistema de recomendación de ítems. Para ello, construí una API RESTful que exponga las descripciones enriquecidas, que serán utilizadas en el sistema de comparación de ítems.

En caso de que prefieras para la creación de descripciones utilizar otra API o modelo, no hay ningún inconveniente. Sentite libre de hacerlo según lo consideres más conveniente.

Tarea

Configuración Inicial

- Asegúrate de tener acceso a Google Colab.
- Obtén las credenciales necesarias para acceder a la API de MercadoLibre y la API de Gemini..

Extracción de Datos

- Accede a la guía de producto en la documentación de MercadoLibre para obtener los endpoints relevantes que proporcionan información descriptiva de los productos.

Generación de descripciones

- Utiliza la API de Gemini para promptear y generar las descripciones de los productos en base a sus características.
- Asegúrate de que los prompts sean en inglés. Por ejemplo:

Python

```
prompt = f"Generate a description for clarity and engagement: '{product_attributes}'"
```

- Se espera que el prompt:
 - Clarifique el propósito, orientando al LLM hacia la creación de una descripción atractiva y relevante para el producto.
 - Defina el tono o estilo adecuado para el producto y el público objetivo.
 - Sea específico sobre el formato o longitud, si se requiere un tamaño específico para la integración en el sistema de recomendación.

Implementación del Script

Desarrolla un proceso en Python que:

- Automatice la extracción de datos de la API de MercadoLibre.
- Identifique y seleccione descripciones para generar en la API de Gemini.
- Reciba y almacene las descripciones en un formato estructurado, y simule persistencia de los datos utilizando JSON/CSV local o SQLite.
- Exponga a través de la API los endpoints que creas necesarios para la explotación de los datos almacenados y enriquecidos por el proceso.

Desarrollo de API

API Endpoint:

- Construir una RESTful API básica que retorne el detalle de los ítems con descripciones enriquecidas.
- La API debe proporcionar campos como nombre del producto, descripción, URL de la imagen, descripción, precio, calificación y especificaciones.
- Incluí manejo básico de errores y comentarios dentro del código para explicar tu lógica.
- Incluí la propuesta de arquitectura y estrategia de observabilidad.

Stack:

- Puedes usar cualquier framework backend de tu elección.

Consideraciones Finales

- Documenta el proceso y cualquier desafío que enfrentaste.
- Incluye un análisis de cómo las mejoras en las descripciones impactan la calidad y efectividad del sistema de recomendación, y las maneras en las que pueden ser consumidas por entidades externas.

Notas

- Asegúrate de manejar las respuestas de la API para evitar cualquier error de comunicación o límites de tasa.
- Considera la ética y la precisión en la creación de las descripciones, evitando adornar o cambiar la sustancia de la información original sin razón justificada.
- Asegúrate de que la API devuelve códigos de error descriptivos y mensajes claros en las respuestas, para facilitar la identificación y resolución de problemas por parte de los usuarios que la consumen.

Entregables

- Código Python en [Google Colab](#) con la extracción de datos de las APIs de MercadoLibre y Gemini.
- Informe detallado con los resultados del caso de uso.
- Implementación de la API RESTful y especificación de los endpoints disponibles.

Puntos que se valoran

- Legibilidad del código.
- Documentación del proceso.
- Correcto análisis de los datos.
- Correcta implementación de tecnologías con AI.
- Manejo correcto y siguiendo buenas prácticas de la arquitectura RESTful en la creación de la API.
- Manejo adecuado de errores y respuestas descriptivas por parte de la API.